



FORMULARIO BASI DI DATI MULTIMEDIALI

Alessandro Zappatore

Università degli studi di Torino
Anno accademico 2025/2026, 2° semestre

1 Modello vettoriale

1.1 Norma LP

$$\|\vec{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

1.2 Modelli Metrici e Distanze

1.2.1 Distanza di Malinowski (L_p)

$$d_p(A, B) = \left(\sum_{i=1}^N |a_i - b_i|^p \right)^{1/p}$$

1.2.2 Distanza di Manhattan (L_1)

$$d_1(A, B) = \sum_{i=1}^N |a_i - b_i|$$

1.2.3 Distanza Euclidea (L_2)

$$d_2(A, B) = \sqrt{\sum_{i=1}^N (a_i - b_i)^2}$$

1.2.4 Distanza di Chebyshev (L_∞)

$$d_\infty(A, B) = \max_i |a_i - b_i|$$

1.2.5 Distanza di Mahalanobis

$$\Delta_{Mah}(\vec{a}, \vec{b}) = \sqrt{(\vec{a} - \vec{b})^T S^{-1} (\vec{a} - \vec{b})}$$

1.2.6 Distanza Quadratica

$$\Delta_{quad}(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T A^{-1} (\vec{x} - \vec{y})}$$

1.3 Similarità

1.3.1 Intersezione di Istogrammi

$$sim_{int}(\vec{a}, \vec{b}) = \frac{\sum_{i=1}^n \min(a_i, b_i)}{\sum_{i=1}^n \max(a_i, b_i)}$$

1.3.2 Dot Product

$$sim_{dot}(\vec{a}, \vec{b}) = \vec{a} \cdot \vec{b} = \sum_{i=1}^n a_i b_i$$

1.4 Similarità del Coseno

$$\cos(\theta) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|}$$

1.4.1 Correlazione di Pearson

$$\rho(\vec{a}, \vec{b}) = \frac{\sum (a_i - \bar{a})(b_i - \bar{b})}{\sqrt{\sum (a_i - \bar{a})^2} \sqrt{\sum (b_i - \bar{b})^2}}$$

1.4.2 Divergenza di Kullback-Leibler

$$\Delta_{KL}(\vec{a}, \vec{b}) = \sum_i a_i \log\left(\frac{a_i}{b_i}\right)$$

1.4.3 Earth Mover's Distance

$$\Delta_{EMD}(\vec{a}, \vec{b}) = \frac{\sum_{i=1}^n \sum_{j=1}^n c_{ij} \cdot a_i b_j}{\sum_{i=1}^n \sum_{j=1}^n a_i b_j} = \sum_{i=1}^n \sum_{j=1}^n cost_{ij}$$

2 Features

2.1 Entropia

$$H(X) = \sum_{x \in X} p(x) \log_2 \frac{1}{p(x)} = - \sum_{x \in X} p(x) \log_2 p(x)$$

2.2 Pesì vettoriali

2.2.1 Term Frequency

$$tf = \frac{n}{K}$$

2.2.2 Inverse Document Frequency

$$idf = \log\left(\frac{N}{m}\right)$$

2.2.3 TF-IDF

$$tf \cdot idf = tf \cdot idf = \frac{n}{K} \cdot \log\left(\frac{N}{m}\right)$$

2.2.4 Normlizzazione di TF-IDF

$$norm_tf_idf = \frac{n}{K} \cdot \frac{\log\left(\frac{N}{m}\right)}{\max idf}$$

2.3 Momenti dei colori

2.3.1 Primo momento

$$Avg_R = \frac{1}{N} \sum_{x,y} R(x,y)$$

2.3.2 Secondo momento

$$STD_R = \sqrt{\frac{1}{N} \sum_{x,y} (R(x,y) - Avg_R)^2}$$

2.3.3 Terzo momento

$$Skew_R = \sqrt[3]{\frac{1}{N} \sum_{x,y} (R(x,y) - Avg_R)^3}$$

2.4 Confronti tra istogrammi dei colori

2.4.1 Distanza Euclidea

$$D_{Euc}(H, K) = \sqrt{\sum_{i=1}^n (H_i - K_i)^2}$$

2.4.2 Intersection Similarity

$$S_{Int}(H, K) = \frac{\sum_{i=1}^n \min(H_i, K_i)}{\sum_{i=1}^n K_i}$$

2.4.3 Quadratic Form Distance

$$D_{quad}^2(H, K) = (H - K)^T A (H - K) = \sum_{i=1}^n \sum_{j=1}^n A_{ij} (H_i - K_i) (H_j - K_j)$$

2.5 Filtri di Sobel

$$G_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix} \quad G_y = \begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

2.5.1 Intensità (Magnitudo)

$$|\nabla| = \sqrt{\delta_x^2 + \delta_y^2}$$

2.5.2 Direzione

$$\theta = \arctan\left(\frac{\delta_y}{\delta_x}\right)$$

2.6 SIFT

2.6.1 Filtro Gaussiano

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{\sigma^2}}$$

2.6.2 Convoluzione

$$L(x, y, \sigma) = G(x, y, \sigma) \otimes I(x, y)$$

2.6.3 Difference of Gaussian (DoG)

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

3 Riduzione della Dimensionalità

3.1 SVD

$$D = U \times S \times V^\top$$

3.2 PCA

$$C = U \times S \times U^\top$$

3.3 MDS

3.3.1 Funzione di Stress

$$\text{Stress} = \sqrt{\frac{\sum_{i < j} (d_{ij} - d'_{ij})^2}{\sum_{i < j} d_{ij}^2}}$$

4 Tensori

4.1 CP Decomposition

$$\mathcal{X} \approx \sum_{r=1}^R \lambda_r (\vec{a}_r \circ \vec{b}_r \circ \vec{c}_r)$$

4.2 Tucker Decomposition

$$\mathcal{X} \approx \mathcal{G} \times_1 A \times_2 B \times_3 C$$

4.2.1 Higher-Order Orthogonal Iteration (HOOI)

$$\min_{\hat{\mathcal{X}}} \|\mathcal{X} - \hat{\mathcal{X}}\| \quad \text{con} \quad \hat{\mathcal{X}} = \mathcal{G} \times_1 A \times_2 B \times_3 C$$

5 Modelli Probabilistici

5.1 Probabilistic LSA (PLSA)

$$P(o, f) = P(o) \sum_{z \in Z} P(f | z) P(z | o)$$

5.1.1 Applicazione Bayes

$$P(o, f) = \sum_{z \in Z} P(z)P(o | z)P(f | z)$$

5.2 Expectation-Maximization (EM)

$$P(z | o, f) = \frac{P(z)P(o | z)P(f | z)}{\sum_{z' \in Z} P(z')P(o | z')P(f | z')}$$

5.2.1 Aggiornamento di $P(f | z)$

$$P(f | z) \propto \sum_{o \in D} P_{data}(o, f)P(z | o, f)$$

5.2.2 Aggiornamento di $P(o | z)$

$$P(o | z) \propto \sum_{f \in F} P_{data}(o, f)P(z | o, f)$$

5.2.3 Aggiornamento di $P(z)$

$$P(z) \propto \sum_{o \in D} \sum_{f \in F} P_{data}(o, f)P(z | o, f)$$

5.3 Latent Dirichlet Allocation (LDA)

$$p(f | a, b) = \int p(c | a) \left(\prod_{i=1}^N \sum_{j=1}^k p(f_i | z_j, b) p(z_j | c) \right) dc$$

6 Hashing

6.1 Locality Sensitive Hashing (LSH)

$$\mathbb{P}[h(o_1) = h(o_2)] = \text{sim}(o_1, o_2)$$

- Se la distanza $d(o_i, o_j) \leq r$, allora $\mathbb{P}[h(o_i) = h(o_j)] \geq P_1$ (alta probabilità di collisione per oggetti vicini).
- Se la distanza $d(o_i, o_j) \geq cr$, allora $\mathbb{P}[h(o_i) = h(o_j)] \leq P_2$ (bassa probabilità di collisione per oggetti lontani).
- $P_1 > P_2$ e $c > 1$.

6.2 Congiunzione di funzioni

$$g_j(o) = (h_{1,j}(o), \dots, h_{k,j}(o))$$

6.3 Disgiunzione tramite Livelli

$$\begin{aligned} g_1(o) &= (h_{1,1}(o), \dots, h_{k,1}(o)) \\ &\vdots \\ g_L(o) &= (h_{1,L}(o), \dots, h_{k,L}(o)) \end{aligned}$$

6.3.1 Numero di livelli

$$L = \log_{1-P_1^k} \delta = \frac{\ln(\delta)}{\ln(1 - P_1^k)}$$

6.4 Costruzione delle funzioni LSH per specifiche metriche

6.4.1 Distanza di Hamming

(r, cr, P_1, P_2) -sensitive ponendo $P_1 = 1 - \frac{r}{d}$ e $P_2 = 1 - c\frac{r}{d}$ (con $c > 1 \implies P_1 > P_2$)

6.4.2 Distanza di Manhattan

$$h_{s_1, \dots, s_d}(\mathbf{x}) = \left(\left\lfloor \frac{x_1 - s_1}{w} \right\rfloor, \dots, \left\lfloor \frac{x_d - s_d}{w} \right\rfloor \right)$$

6.4.3 Distanza Euclidea

$$h_{\mathbf{p}, b}(\mathbf{x}) = \left\lfloor \frac{\mathbf{p} \cdot \mathbf{x} + b}{w} \right\rfloor$$

7 Clustering

7.1 Compattezza [massimizza]

$$\text{compactness}(C_i) = \sum_{o_k \neq o_l; o_k, o_l \in C_i} \text{sim}(o_k, o_l)$$

7.2 Root Mean Square Error (RMSE) [minimizza]

$$\text{RMSE}(C) = \frac{1}{k} \sum_{1 \leq i \leq k} \sqrt{\frac{1}{|C_i|} \sum_{o_j \in C_i} (|o_j - \mu_i|^2)}$$

7.3 Dimensione bilanciata [massimizza]

$$\text{entropy}(C) = \sum_{1 \leq i \leq k} P(C_i) \log \left(\frac{1}{P(C_i)} \right)$$

7.4 Separazione [massimizza]

$$\text{min_separation}(C_i) = \min_{o_l \in C_i, o_k \notin C_i} (\text{dist}(o_k, o_l))$$

7.5 Separazione in grado [minimizza]

$$\text{Total Cut} = \sum_{C_i \neq C_j; C_i, C_j \in C} \text{cut}(C_i, C_j)$$

7.6 Espansione [minimizza]

$$\text{expansion}(C_i, C_j) = \frac{\text{cut}(C_i, C_j)}{\min\{|C_i|, |C_j|\}}$$

7.7 Cheeger ration

$$\text{ratio}_{\text{Cheeger}}(C_i) = \frac{\sum_{C_i \neq C_j; C_i, C_j \in C} \text{cut}(C_i, C_j)}{\min\{\sum_{o_k \in C_i} \text{degree}(o_k), \sum_{o_k \notin C_i} \text{degree}(o_k)\}}$$

7.8 Integrità intra-cluster

$$integrity(C_i) = \min_{\langle C_{i,1}, C_{i,2} \rangle \in cuts(C_i)} expansion(C_{i,1}, C_{i,2})$$

7.9 Modularità

$$modularity(C) = \sum_{C_i \in C} \left[\frac{cut(C_i, C_i)}{|E|} - \left(\frac{\sum_{C_j \in C} cut(C_i, C_j)}{|E|} \right)^2 \right]$$

7.10 K-Means

$$RMSE_m = \sqrt{\frac{1}{N} \sum_{i=1}^N [\hat{F}_m(z_i) - F_m(z_i)]^2}$$

7.10.1 Globale

$$RMSE = \frac{1}{M} \sum_{m=1}^M RMSE_m$$

8 Classificazione

8.1 Support Vector Machines (SVM)

8.1.1 Iper piano

$$\vec{w} \cdot \vec{x} + b = 0$$

8.1.2 Confini

$$\vec{w} \cdot \vec{x} + b = +1 \quad \text{e} \quad \vec{w} \cdot \vec{x} + b = -1$$

8.1.3 Margine

$$\frac{2}{\|\vec{w}\|}$$

8.2 Weighted k-NN

$$w_i = \frac{1}{dist(x_{new}, x_i)}$$

8.3 Selezione delle feature

8.3.1 Fisher's discriminant ratio (FSR)

$$FSR(f_i) = \frac{(\mu_{i,1} - \mu_{i,2})^2}{\sigma_{i,1}^2 + \sigma_{i,2}^2}$$

8.4 Classificazione Bayesiana

$$p(C_j | O_i) = \frac{p(O_i | C_j)p(C_j)}{p(O_i)}$$

8.4.1 Naive Bayes

$$p(O_i | C_j) = \prod_{k=1}^n p(f_{i,k} | C_j)$$

8.4.2 Divergenza di Kullback-Leibler

$$D_{KL}(p_1 \parallel p_2) = \sum_x p_1(x) \log \frac{p_1(x)}{p_2(x)}$$

8.4.3 Informazione Mutua

$$D_{ij} = I(p(f_i \wedge f_j), p(f_i)p(f_j))$$

9 Reti neurali

9.1 Deconomposizione LR

$$X = LR$$

9.1.1 Funzione di costo [minimizza]

$$Loss = \Delta(X, \tilde{X}) = \epsilon$$

9.1.2 Encoder/Decoder

$$XR^{-1} = L \quad LR = \tilde{X}$$

9.1.3 Non-negative Matrix Factorization (NMF)

$$L_{ij} \geq 0 \text{ e } R_{jk} \geq 0$$

9.1.4 Regolarizzazione L1

$$Loss = \Delta(X, \tilde{X}) + \lambda(\|L\|_1 + \|R\|_1)$$

9.2 Deep Auto-Encoder

$$XR_1^{-1}R_2^{-1} \dots R_l^{-1} = L' \rightarrow L'R_l \dots R_2R_1 = \tilde{X}$$

9.3 Funzioni di Attivazione

9.3.1 Rectified Linear Unit (ReLU)

$$ReLU(x) = \max(0, x)$$

9.3.2 Soft Plus

$$SoftPlus(x) = \log(1 + e^x)$$

9.3.3 Logistic Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

9.3.4 Hyperbolic Tangent

$$HT(x) = \frac{e^{2x} - 1}{e^{2x} + 1}$$

10 Relevance Feedback

10.1 Spostamento della Query (Rocchio)

$$sep = dist \left(Q, \sum_{O_i \in Ir} O_i - \sum_{O_i \in Rel} O_i \right)$$

10.1.1 Nuova query

$$Q' = Q + \left(c_{rel} \times \sum_{O_i \in Rel} O_i \right) - \left(c_{ir} \times \sum_{O_i \in Ir} O_i \right)$$

10.2 Ricalibrazione dei Pesi delle Feature

$$sig(f_k) = \frac{\log \left(\frac{p(f_k|R)}{1-p(f_k|R)} \right)}{\log \left(\frac{p(f_k|I)}{1-p(f_k|I)} \right)}$$

10.2.1 Caso A: Se f_k NON era un termine della query iniziale

$$p(f_k | R) \approx p(f_k | \text{Retrieved \& Relevant})$$

10.2.2 Caso B: Se f_k ERA un termine della query iniziale

$$sim(o, q) = \sum_{i=1}^n w_i f_i > T$$

$$sim(o, q) = w_j f_j + sim_{(-j)}(o, q) \geq T$$

	$f_j = 1$ (Presente)	$f_j = 0$ (Assente)
$sim_{(-j)}(o, q) \leq T$	a	0
$sim(o, q) > T$	b	c

Tabella 1: Matrice di classificazione rispetto al cut-off T scorporato dalla feature j

$$p(f_k | R) \approx \frac{b}{b + c}$$

10.3 Ranking Bayesiano dei Documenti

$$p(R | O_i) > p(R | O_j)$$

10.3.1 Applicazione del Teorema di Bayes

$$p(R | O_i) = \frac{p(O_i | R)p(R)}{p(O_i | R)p(R) + p(O_i | I)p(I)}$$

10.3.2 Rapporto delle probabilità

$$\frac{p(O_i | R)}{p(O_i | I)} > \frac{p(O_j | R)}{p(O_j | I)} \Leftrightarrow \text{sim}(Q, O_i) > \text{sim}(Q, O_j)$$

10.3.3 Ipotesi Naive

$$p(O_i | R) \approx \prod_{k=1}^n p(f_{i,k} | R) \quad p(O_i | I) \approx \prod_{k=1}^n p(f_{i,k} | I)$$
$$\prod_{k=1}^n \frac{p(f_{i,k} | R)}{p(f_{i,k} | I)} > \prod_{k=1}^n \frac{p(f_{j,k} | R)}{p(f_{j,k} | I)}$$

10.3.4 Trasformazione Logaritmica per la linearizzazione

$$\sum_{k=1}^n \log \left(\frac{p(f_{i,k} | R)}{p(f_{i,k} | I)} \right) > \sum_{k=1}^n \log \left(\frac{p(f_{j,k} | R)}{p(f_{j,k} | I)} \right)$$