



UNIVERSITÀ
DI TORINO

IMPROVING RETRIEVAL PERFORMANCES BY RELEVANCE FEEDBACK

Alessandro Zappatore

UNIVERSITÀ DEGLI STUDI DI TORINO

10/07/2026

Il Problema della Query Iniziale

- La formulazione della query originale non è trasparente per la maggior parte degli utenti, i quali spesso non conoscono nel dettaglio la composizione della collezione di documenti.
- La prima operazione di ricerca dovrebbe essere considerata solo un "tentativo" per recuperare alcuni documenti utili.
- **L'idea del Relevance Feedback:** Esaminare i primi documenti recuperati, valutarne la rilevanza (da parte dell'utente) e usare queste informazioni per costruire in modo automatico una nuova query migliorata.

Perché usare il Relevance Feedback?

- É un processo automatico che nasconde all'utente i dettagli complessi della riformulazione della query.
- Suddivide l'operazione di ricerca in una sequenza di piccoli passi, avvicinandosi gradualmente all'area tematica desiderata.
- Fornisce un processo controllato per enfatizzare i termini importanti (presenti nei documenti rilevanti) e de-enfatizzare altri (presenti in quelli non rilevanti).

Rappresentazione delle Query e dei Documenti

- Nel modello vettoriale, le query Q e i documenti D sono rappresentati come vettori t -dimensionali.

$$Q_0 = (q_1, q_1, \dots, q_t)$$

- La similarità tra un documento e una query è calcolata tramite il prodotto scalare dei vettori.

$$Sim(D, Q) = \sum_{k=1}^t d_i \cdot q_i$$

- Inizialmente, il feedback di rilevanza è stato progettato come migrazione del vettore della query da un'area dello spazio verso un'altra

- Teoricamente, la query migliore (Q_{opt}) per recuperare n documenti rilevanti da una collezione di N documenti separa perfettamente i documenti rilevanti da quelli non rilevanti.

$$Q_{opt} = \frac{1}{n} \sum_{\text{items}}^{\text{relevant}} \frac{D_i}{|D_i|} - \frac{1}{N-n} \sum_{\text{items}}^{\text{non relevant}} \frac{D_i}{|D_i|}$$

- Tuttavia, questa formula teorica non è utilizzabile all'inizio perché non conosciamo in anticipo i documenti rilevanti

- Nella pratica, modifichiamo la query iniziale (Q_0) aggiungendo i documenti noti come rilevanti e sottraendo quelli noti come non rilevanti.


$$Q_1 = Q_0 + \frac{1}{n_1} \sum \frac{D_i}{|D_i|} - \frac{1}{n_2} \sum \frac{D_i}{|D_i|}$$

- Il modello generale di **Rocchio** introduce dei moltiplicatori (α, β, γ) per bilanciare l'importanza della query originale rispetto ai documenti di feedback.

$$Q_{i+1} = \alpha Q_i + \beta \sum_{rel} \frac{D_i}{|D_i|} - \gamma \sum_{nonrel} \frac{D_i}{|D_i|}$$

Il Feedback di Rilevanza in Azione

- La query originale Q_0 viene modificata per creare una nuova query (Q' o Q'').
- Se il documento D_1 è rilevante, la nuova query Q' si sposta significativamente verso D_1 .
- Il processo è concettualmente semplice e altera i pesi dei termini per avvicinarsi ai concetti target.



L'Alternativa: Metodi Probabilistici

- I metodi probabilistici si basano sul principio di ordinare i documenti in ordine decrescente in base alla probabilità di rilevanza.
- Vengono calcolate due probabilità fondamentali per ogni termine i :
 - p_i : probabilità che il termine sia in un documento rilevante.
 - μ_i : probabilità che il termine sia in un documento non rilevante.
- Regola di recupero ottimale:

$$\log \frac{Pr(x \mid rel)}{Pr(x \mid nonrel)}$$

- Similarità probabilistica:

$$sim(D, Q) = \sum_{i=1}^t d_i \log \frac{p_i(1 - \mu_i)}{u_i(1 - p_i)}$$

- **Ricerca iniziale:** Non avendo informazioni di rilevanza, p_i viene spesso posto a 0.5 costante, e u_i approssimato dalla distribuzione dell'intera collezione (n_i/N).
- **Fase di Feedback:** Si utilizzano le statistiche dei documenti recuperati e giudicati (numero totale di rilevanti R , e quanti di questi contengono il termine r_i).

$$p_i = \frac{r_i}{R} \quad \text{e} \quad u_i = \frac{n_i - r_i}{N - R}$$

- Le formule probabilistiche classiche falliscono per valori piccoli di R o r_i (ad esempio causando logaritmi di zero).
- Soluzione standard:** Viene aggiunto un fattore di aggiustamento di 0.5 per livellare le probabilità.

$$p_i = \frac{r_i + 0.5}{R + 1} \quad \text{e} \quad u_i = \frac{n_i - r_i + 0.5}{N - R + 1}$$

- Soluzione alternativa:** Usare come stima iniziale le probabilità della collezione generale (n_i/N) anziché il fattore fisso 0.5, che produce stime migliori quando pochi documenti rilevanti sono noti.

$$p'_i = \frac{r_i + n_i/N}{R + 1}$$

Set di Dati per l'Esperimento

- Sono state utilizzate 6 diverse collezioni documentali per valutare i metodi, variando per dominio.
- **Collezioni:** MED (1033 doc), INSPEC (12684 doc), CACM, CISI, CRAN, NPL.
- Ogni collezione possiede caratteristiche diverse in termini di lunghezza media dei vettori e frequenza.

Collection	Number of Vectors (Documents or Queries)	Average Vector Length (Number of Terms)	Standard Deviation of Vector Length	Average Frequency of Terms in Vectors	Percentage of Terms in Vectors with frequency 1
CACM documents	3204	24.52	21.21	1.35	80.93
queries	64	10.80	6.43	1.15	88.68
CISI documents	1460	46.55	19.38	1.37	80.27
queries	112	28.29	9.49	1.38	78.36
CRAN documents	1398	53.13	22.53	1.58	69.50
queries	225	9.17	3.19	1.04	95.69
INSPEC documents	12684	32.50	14.27	1.78	61.06
queries	84	15.63	8.66	1.24	83.78
MED documents	1033	51.60	22.78	1.54	72.70
queries	30	10.10	6.03	1.12	90.76
NPL documents	11429	19.96	10.84	1.21	84.03
queries	100	7.16	2.36	1.00	100.00

Come è Stata Condotta la Valutazione

- **Ricerca iniziale:** Pesi vettoriali ad alta qualità calcolati col prodotto tra "term frequency" (TF) e "inverse collection frequency" (IDF) per massimizzare le performance di base.

$$w_i = \frac{\left(0.5 + 0.5 \frac{tf_i}{\max tf}\right) \cdot \log \frac{N}{n_i}}{\sqrt{\left(0.5 + 0.5 \frac{tf_i}{\max tf}\right)^2 \left(\log \frac{N}{n_i}\right)^2}}$$

- Si valuta il feedback usando i primi 15 documenti recuperati, marcati come rilevanti o non rilevanti.
- **Residual Collection Evalutaion:** Per evitare falsi miglioramenti (documenti già visti che risalgono il ranking), i documenti già valutati dall'utente vengono rimossi dalle ricerche successive, misurando solo la capacità di trovare nuovi documenti rilevanti.

Oltre al ricalcolo dei pesi, quali nuovi termini aggiungere alla query di feedback?

- Sono stati testati vari metodi:

- ❶ **Nessuna espansione:** Uso esclusivo dei termini originali ripesati.
- ❷ **Espansione totale:** Vengono aggiunti alla query tutti i termini estratti dai documenti rilevanti recuperati.
- ❸ **Espansione parziale:** Aggiunta solo dei termini "più comuni" o con il "peso maggiore", per risparmiare risorse e spazio di memorizzazione.

Sono stati confrontati in totale 72 test diversi incrociando 12 metodi principali con espansione e tipi di vettore (pesati vs. binari).

- **Metodi Vettoriali Principali:**

- **Ide dec-hi:** Aggiunge i documenti rilevanti, ma sottrae solo il primo documento non rilevante.
- **Ide regular:** Sottrae tutti i documenti non rilevanti esaminati.
- **Standard Rocchio:** Pesi ridotti basati su vari moltiplicatori ($\beta = 0.75, \gamma = 0.25$).

- **Metodi Probabilistici:**

- Conventional (con 0.5) vs Adjusted.

Vettori Pesati vs Vettori Binari

- L'uso di termini pesati per i documenti produce risultati di gran lunga superiori rispetto all'ambiente vettoriale binario.
- **Metodo Vincitore ("Ide dec-hi")**: É risultato essere il miglior metodo assoluto. L'utilizzo di un solo documento non rilevante come punto da cui "allontanare" la query, unito all'aggiunta di tutti i termini rilevanti, offre le migliori prestazioni precision-recall.
- L'espansione totale è leggermente superiore, ma l'espansione per "termini più comuni" è preferibile in ottica di efficienza computazionale.
- I metodi probabilistici risultano, in generale, meno efficaci e computazionalmente più gravosi rispetto ai semplici metodi di modifica vettoriale.

Relevance Feedback Method	Rank of Method and Avg Precision	CACM 3204 docs 64 queries	CISI 1460 docs 112 queries	CRAN 1397 docs 225 queries	INSPEC 12684 docs 84 queries	MED 1033 docs 30 queries	Average
Ide (dec hi)	Rank	1	2	8	1	1	2.2
- expand by all terms	Precision Improvement	.2704 +86%	.1742 +47%	.3011 160%	.2140 +56%	.6305 +88%	+87%
- expand by most common terms	Rank	4	1	13	2	3	4.6
	Precision Improvement	.2479 +70%	.1924 +63%	.2498 +116%	.1976 +44%	.6218 +86%	+76%

L'Anomalia NPL (National Physical Laboratory)

- A differenza delle altre 5 collezioni, i risultati per la collezione NPL hanno mostrato prestazioni superiori usando assegnazioni di termini **binari** anzichè pesati.
- **Perché?** I vettori dei documenti e delle query di NPL sono estremamente brevi (media query: 7.16 termini; doc: 19.96 termini), e la frequenza media dei termini nel documento è solo di 1.21.
- Con termini che appaiono solo una volta e query così ristrette, le operazioni di normalizzazione della lunghezza e della term-frequency persono di efficacia, rendendo il binario preferibile.