



UNIVERSITÀ  
DI TORINO

# ON SPECTRAL CLUSTERING



Alessandro Zappatore

UNIVERSITÀ DEGLI STUDI DI TORINO

10/07/2026

# Sfide del Clustering Tradizionale

- Trovare buoni cluster in  $\mathbb{R}^n$  è un'applicazione fondamentale nel machine learning.
- **Approcci Generativi** (es. **EM** o **K-Means**): Spesso usano stimatori di densità parametrici che richiedono assunzioni rigide semplificative (come supporre che la densità di ogni cluster sia Gaussiana).
- **Problema dei Minimi Locali**: La log-likelihood in questi algoritmi iterativi soffre della presenza di molti minimi locali, richiedendo quindi multipli riavvii per trovare una buona soluzione.



# Clustering Spettrale: Una nuova prospettiva

- Negli ultimi anni sono emersi i "metodi spettrali", utilizzati con successo in computer vision e design VLSI.
- Questi algoritmi utilizzano i principali autovettori di una matrice derivata dalla distanza tra i punti dei dati.
- **Limiti dell'analisi precedente:** Spesso ci si concentrava sull'uso del secondo autovettore del Laplaciano di un grafo per effettuare un taglio semi-ottimale (bipartizione ricorsiva per trovare  $k$  cluster).
- **L'intuizione:** Sperimentalmente si è notato che calcolare direttamente una partizione a  $k$  vie utilizzando  $k$  autovettori simultaneamente restituisce risultati migliori. L'algoritmo proposto analizza e utilizza simultaneamente questi  $k$  autovettori.

# L'Algoritmo di Clustering Spettrale: Costruire le Matrici

Dato un insieme di punti  $S = \{s_1, \dots, s_n\} \in \mathbb{R}^l$  da raggruppare in  $k$  cluster:

- 1 **Matrice di Affinità ( $A$ ):** Viene calcolata la matrice  $A \in \mathbb{R}^{n \times n}$  definita dalla formula:

$$A_{ij} = \exp \left( -\frac{\|s_i - s_j\|^2}{2\sigma^2} \right) \quad \text{se } i \neq j, \text{ e } A_{ii} = 0$$

Il parametro  $\sigma^2$  controlla la rapidità con cui l'affinità decade in base alla distanza tra i due punti.

- 2 **Matrice Laplaciana Normalizzata ( $L$ ):** Si definisce una matrice diagonale  $D$  dove l'elemento  $(i, i)$  è la somma della  $i$ -esima riga di  $A$ . Successivamente si costruisce la matrice:

$$L = D^{-\frac{1}{2}} A D^{-\frac{1}{2}}$$

# L'Algoritmo di Clustering Spettrale: Autovettori e K-means

- 3 **Estrazione degli Autovettori:** Si trovano i  $k$  autovettori più grandi di  $L$  (chiamati  $x_1, x_2, \dots, x_k$ ) e si impilano in colonna per formare la matrice  $X \in \mathbb{R}^{n \times k}$ .
- 4 **Rinormalizzazione ( $Y$ ):** Ogni riga di  $X$  viene normalizzata per avere lunghezza unitaria formando la matrice  $Y$ :

$$Y_{ij} = \frac{x_{ij}}{\sqrt{\sum_j X_{ij}^2}}$$

- 5 **Clustering Finale:** Trattando le righe di  $Y$  come punti in  $\mathbb{R}^k$ , si applica l'algoritmo K-means (o un altro che minimizzi la distorsione) per raggrupparli in  $k$  cluster.
- 6 **Assegnazione:** Il punto originale  $s_j$  viene assegnato al cluster  $j$  se e solo se la riga  $i$  della matrice  $Y$  è stata assegnata al cluster  $j$ .

# L'Intuizione Geometrica dietro l'Algoritmo

- **Il problema:** I cluster naturali nello spazio originale dei dati (es. in  $\mathbb{R}^2$ ) spesso non corrispondono a regioni convesse, facendo fallire l'applicazione diretta di K-means.
- **La soluzione:** Mappando i punti nello spazio  $\mathbb{R}^k$  (le righe della matrice  $Y$ ), i dati formano cluster estremamente "compatti".
- Sorprendentemente, in questo nuovo spazio, i cluster si posizionano sulla superficie di una sfera a  $k$ -dimensioni, e si trovano ad angoli di  $90^\circ$  gli uni rispetto agli altri, rispetto all'origine. Questo rende l'esecuzione di K-means banale ed efficace.

# Analisi Teorica: Quando i cluster sono separati all'infinito

- Per capire l'algoritmo, si immagina il caso "ideale" in cui punti di cluster diversi sono a distanza infinita. Questo si traduce nell'azzeramento di tutte le affinità  $A_{ij}$  per punti in cluster differenti.
- In questo scenario, la matrice modificata  $\hat{A}$  (e la derivata  $\hat{L}$ ) diventa a blocchi diagonali.
- Ciascun blocco ha un autovettore principale con autovalore 1, mentre gli autovalori successivi sono strettamente minori di 1.
- **La matrice ortogonale:** Estraendo i 3 (o  $k$ ) principali autovettori, i punti originali verranno mappati come  $k$  punti reciprocamente ortogonali sulla superficie di una sfera di raggio unitario in  $\mathbb{R}^k$ . I cluster calcolati su  $Y$  corrisponderanno perfettamente al clustering "reale".

# Il Caso Generale e la Teoria delle Perturbazioni

- **La Teoria delle Perturbazioni:** Nel caso generale, i blocchi fuori dalla diagonale di  $A$  non sono nulli. La matrice reale è vista come una perturbazione del caso "ideale" a cluster separati all'infinito:

$$A = \hat{A} + E.$$

- La stabilità degli autovettori dipende dall'**eigengap**, ovvero la differenza tra il terzo e il quarto autovalore della matrice Laplaciana:

$$\delta = |\lambda_3 - \lambda_4|$$

- Sapendo che per costruzione  $\lambda_3 = 1$  nel caso di cluster ideali, e che  $\lambda_4$  rappresenta il massimo tra i secondi autovalori dei singoli cluster ( $\lambda_4 = \max_i \lambda_2^i$ ), per avere un algoritmo stabile è necessario che  $\lambda_4$  sia significativamente distante da 1.

# Assunzioni: Coesione interna e Separazione esterna

- **Assunzione 1:** Ogni cluster deve essere "coeso". Esiste  $\delta > 0$  tale che, per ogni cluster  $i = 1, \dots, k$ :

$$\lambda_2^i \leq 1 - \delta$$

- **Assunzione 1.1 (Costante di Cheeger):** Quantifica quanto sia difficile spezzare a metà il cluster  $i$ . Definendo la costante di Cheegher  $h(S_i)$  come:

$$h(S_i) = \min_{I \subset \{1, \dots, n_i\}} \frac{\sum_{j \in I, k \notin I} A_{jk}^{ii}}{\min\{\sum_{j \in I} d_j^i, \sum_{k \notin I} d_k^i\}}$$

Si assume che esista un  $\delta > 0$  tale che  $\frac{(h(S_i))^2}{2} \geq \delta$  per ogni  $i$ .

- **Assunzione A2:** Limita le affinità totali tra coppie di cluster diversi. Esiste un  $\epsilon_1 > 0$  fisso tale che, per ogni coppia di cluster densi  $i_1 \neq i_2$ :

$$\sum_{j \in S_{i_1}} \sum_{k \in S_{i_2}} \frac{A_{jk}^2}{d_j d_k} \leq \epsilon_1$$

- **Assunzione A3:** I punti sono più connessi al proprio cluster che agli altri. Esiste un  $\epsilon_2 > 0$  tale che, per ogni punto  $j$  nel cluster  $S_i$ :

$$\frac{\sum_{k \notin S_i} A_{jk}}{d_j} \leq \epsilon_2 \left( \sum_{k,l \in S_i} \frac{A_{kl}^2}{d_k d_l} \right)^{-\frac{1}{2}}$$

- **Assunzione A4:** Nessun punto è significativamente "meno connesso" degli altri all'interno dello stesso cluster. Esiste una costante  $C > 0$  tale che per ogni punto  $j$ :

$$d_j^i \geq \frac{\sum_{k=1}^{n_i} d_k^i}{C_{n_i}}$$



# Il Teorema di Convergenza

- **Teorema 2 (Risultato Principale):** Supponendo valide le assunzioni A1, A2, A3 e A4, definiamo  $\epsilon = \sqrt{k(k-1)\epsilon_1 + k\epsilon_2^2}$ . Se  $\delta > (2 + \sqrt{2})\epsilon$ , allora le righe della matrice  $Y$  formeranno  $k$  cluster stretti attorno a vettori ortogonali  $r_1, \dots, r_k$  (distanti  $90^\circ$  sulla sfera  $k$ -dimensionale). La distorsione massima di questo clustering è limitato dalla disuguaglianza:

$$\frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{n_i} \|y_j^i - r_i\|_2^2 \leq 4C \left(4 + 2\sqrt{k}\right)^2 \frac{\epsilon^2}{(\delta - \sqrt{2}\epsilon)^2}$$

# Test Empirici e Automazione

- L'algoritmo è stato testato su sette problemi di clustering.
- I risultati sono stati eccellenti, riuscendo a raggruppare fedelmente forme complesse, set non convessi o non chiaramente separati.
- **Scelta Automatica di  $\sigma^2$** : Invece di far scegliere il parametro all'utente, l'analisi suggerisce un metodo automatico. L'algoritmo effettua una ricerca per diversi valori di  $\sigma^2$  ed estrae il valore che fornisce i cluster più "stretti" (a minore distorsione) nelle righe della matrice  $Y$ .
- Inoltre, per inizializzare efficacemente il K-means, si può sfruttare il fatto che i centri attesi si trovano a circa  $90^\circ$  di distanza l'uno dall'altro.



# Superare i Metodi Esistenti

- L'algoritmo eccelle dove altri metodi si rompono.
- **K-means standard**: Fallisce quando i cluster non definiscono regioni convesse.
- **Algoritmi "Connected Components"**: Usano un approccio a soglia rigida sulla distanza, ma sono estremamente non robusti alla presenza di outlier o ponti.
- **Meila & Shi / Kannan et al.**: Seppur simili, l'algoritmo di Ng et al. differisce per la rinormalizzazione ortogonale. L'algoritmo di Meila & Shi usa gli autovettori della matrice delle affinità non simmetrica e non rinormalizza  $X$ , diventando così vulnerabile a cattivi clustering se il grado di connessione intra-cluster varia sostanzialmente tra cluster diversi. Kannan et al. usano vettori singolari individuali portando spesso a risultati scarsi.

# Superare i Metodi Esistenti

